

Mục 4. Trục đánh giá - Công thức và áp dụng đo lường

Phản phụ trách: Hoàng Cao Sơn - đánh giá Responsible AI, frontend demo nhẹ, Feature Importance và checklist QA.

Bối cảnh: Báo cáo V4 hiện có bảng kiểm thử 5 trục nhưng còn thiếu công thức, ngưỡng đo và cách áp dụng cụ thể vào pipeline Random Forest + FastAPI của dự án.

1. Căn cứ từ slide của thầy và báo cáo V4

Phản đánh giá cần đi theo đúng tinh thần slide Model Assessment: đánh giá thực nghiệm trên tập dữ liệu quan sát được, dùng thước đo định lượng và tách train/validation/test hoặc train/test rõ ràng. Với bài toán hồi quy giá cả phê, metric chính là sai số dự báo như MAE, RMSE và R^2 .

Slide AI Ethics và Responsible AI nhấn mạnh AI không chỉ cần đúng về accuracy mà còn cần kiểm tra bias, robustness, explainability và tác động xã hội. Vì vậy mục này không chỉ ghi một bảng test chung, mà phải chỉ rõ công thức đo, input kiểm thử, evidence hiện có và giới hạn sử dụng.

Với hệ thống hiện tại, Robustness không nên lấy prompt injection làm test chính, trừ khi nhóm thật sự có module LLM. Test đúng hơn cho phần của Sơn là dữ liệu thiếu, ngoại lai, sai range, lệch coverage theo tỉnh và lỗi API/model.

2. Bộ công thức đánh giá

2.1. Reliability - Tính tin cậy

Đo mô hình dự báo giá có sai số bao nhiêu trên tập test 2025, dùng split theo thời gian để tránh data leakage.

Mean Absolute Error (Sai số tuyệt đối trung bình):

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Root Mean Squared Error (Căn bậc hai của sai số bình phương trung bình):

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

R-squared (Hệ số xác định):

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- **MAE**: sai số trung bình, dễ giải thích cho người dùng bằng VND/kg.
- **RMSE**: phạt nặng các dự báo sai lớn, dùng để phát hiện model kém ổn định.
- **R²**: nếu âm, model còn kém hơn dự đoán trung bình; phải ghi rõ đây chỉ là baseline học thuật.

2.2 Bias/Fairness - Thiên lệch vùng

Đo model có sai khác quá lớn giữa các tỉnh/khu vực hay không. Mỗi tỉnh cần tính sai số riêng rồi so sánh độ lệch.

Sai số riêng theo tỉnh/khu vực:

$$MAE_p = \frac{1}{n_p} \sum_{i \in p} |y_i - \hat{y}_i|$$

Độ lệch sai số giữa các vùng:

$$BiasGap = \max(MAE_p) - \min(MAE_p)$$

Tỷ lệ lệch tương đối:

$$RelativeBiasGap = \frac{BiasGap}{MAE_{all}}$$

Độ phủ dữ liệu theo tỉnh/khu vực:

$$Coverage_p = \frac{ObservedRecords_p}{ExpectedRecords_p}$$

- Nếu $Coverage_p$ thấp, kết quả ở tỉnh đó phải gắn cảnh báo.
- Nếu $RelativeBiasGap$ cao, không được nói mô hình công bằng như nhau cho mọi tỉnh.
- Demo nên ưu tiên vùng có coverage tốt; tránh dùng vùng proxy/fill nhiều làm case chính.

2.3 Robustness - Khả năng chống nhiễu

Đo hệ thống có chịu được dữ liệu thiếu, dữ liệu ngoài ngưỡng, outlier và biến động cực đoan hay không.

Tỷ lệ dữ liệu thiếu:

$$MissingRate = \frac{MissingCells}{TotalCells}$$

Quy tắc phát hiện outlier bằng IQR:

$$x < Q_1 - 1.5 \times IQR \text{ hoặc } x > Q_3 + 1.5 \times IQR$$

Độ tăng sai số khi stress test:

$$MAE\ Lift_{stress} = \frac{MAE_{stress} - MAE_{base}}{MAE_{base}} \times 100\%$$

- Dữ liệu thiếu phải được fill hợp lý hoặc bị từ chối rõ ràng.
- Nhiệt độ, độ ẩm, lượng mưa ngoài range phải bị validate trước khi gọi model.
- Nếu stress test làm MAE tăng mạnh, UI/report phải cảnh báo model yếu trước biến động hiểm.

2.4 Social Impact - Tác động xã hội

Đo kết quả có giúp nông dân hiểu và dùng được ở mức tham khảo hay không, thay vì chỉ trả về con số kỹ thuật.

Độ nhẹ của response/API để phù hợp mạng yếu:

$$PayloadSizeKB = \frac{ResponseBytes}{1024}$$

Tỷ lệ đạt checklist tác động xã hội:

$$SocialChecklistScore = \frac{PassedSocialChecks}{TotalSocialChecks} \times 100\%$$

Các check tối thiểu:

- Có disclaimer: AI chỉ hỗ trợ tham khảo, không thay thế quyết định tài chính/bán hàng.
- Có đơn vị dễ hiểu: VND/kg, khoảng tin cậy, mức rủi ro.

- Có cảnh báo vùng dữ liệu yếu.
- Frontend/response nhẹ, đọc được trên thiết bị phổ thông hoặc mạng yếu.

2.5 Transparency/Explainability - Minh bạch

Do hệ thống có giải thích lý do dự báo bằng Feature Importance và metadata hay không.

Độ phủ của top K feature quan trọng nhất:

$$TopKImportanceCoverage = \frac{\sum_{j=1}^k Importance_j}{\sum_{j=1}^m Importance_j}$$

Mức đầy đủ của phần giải thích:

$$ExplanationCompleteness = \frac{AvailableExplanationFields}{RequiredExplanationFields} \times 100\%$$

Các field nên có trong:

response/demo: predicted_price_vnd, confidence_interval, top_features, model_version, disclaimer.

3. Áp dụng vào dự án hiện tại

Trục	Cách đo trong dự án	Kết quả/evidence hiện có	Kết luận đưa vào báo cáo
Reliability	Train 2022-2024, test 2025. Đo MAE, RMSE, R ² .	Local baseline/mock: MAE 2,705; RMSE 3,340; R ² 0.203. Brief real-data: MAE 13,874; RMSE 17,261; R ² -1.0213.	Không overclaim. Nếu dùng real-data, ghi model là baseline chứng minh pipeline, chưa đủ làm tư vấn tài chính.
Bias	Tính MAE và coverage theo tỉnh/khu vực. So sánh BiasGap và Coverage.	Phạm vi 4 tỉnh Tây Nguyên. Brief Sơn ghi Dak Nong/Dak R'lap là vùng rủi ro coverage/proxy.	Demo chính nên chọn vùng coverage tốt. Vùng yếu phải hiện cảnh báo, không áp dụng ngoài Tây Nguyên.
Robustness	Kiểm tra missing, outlier, invalid range, API/model lỗi và stress scenario.	Stress mock: price_crash làm MAE tăng 88.3%, RMSE tăng 149.1%; both làm MAE tăng 86.9%.	Cần cảnh báo Black Swan. Model ổn trong phân bố lịch sử, yếu khi thị trường biến động cực đoan.
Social Impact	Checklist disclaimer, đơn vị dễ hiểu, vùng rủi ro, payload/UI nhẹ, lỗi rõ.	README và docs yêu cầu AI chỉ tham khảo. Frontend/API cần hiển thị disclaimer, confidence interval và warning.	Phù hợp mục tiêu học thuật. Giá trị xã hội nằm ở hỗ trợ tiếp cận thông tin, không thay quyết định bán hàng.
Transparency	Feature Importance, top features trong	backend/services/predictor.py có top 3 feature	Giải thích dự báo bằng feature quan trọng nhất, nhưng ghi rõ đây không

	response, model metadata.	explanations. metadata. json có experiment id và metrics.	phải quan hệ nhân quả tuyệt đối.
--	---------------------------	---	----------------------------------

4. Bảng test nên đưa vào mục 4

Mã test	Trục đánh giá	Input/cách chạy	Công thức/metric	Kết quả kỳ vọng
SON_REL_01	Reliability	Train trên 2022-2024, test trên 2025.	MAE, RMSE, R ²	Có bảng sai số rõ ràng VND/kg. Nếu R ² âm, ghi limitation thay vì nói model chính xác cao.
SON_BIAS_02	Bias/Fairness	Chạy dự báo và gom sai số theo Đắc Lắc, Gia Lai, Đắc Nông, Lâm Đồng.	MAE_p, BiasGap, RelativeBiasGap, Coverage_p	Vùng sai số cao/coverage thấp có warning. Không demo chính bằng vùng dữ liệu yếu.
SON_ROB_03	Robustness	Thiếu độ ẩm, mưa âm/quá lớn, nhiệt độ vượt range, giá lịch sử outlier.	MissingRate, OutlierRate, validation pass/fail	Hệ thống không crash; hoặc fill/cap hợp lý, hoặc trả lỗi rõ qua API/UI.
SON_ROB_04	Robustness	Stress scenario: price crash, heat wave, both.	MAE_Lift_Stress, RMSE_Lift_Stress	Nếu lift cao, báo cáo phải nói model yếu với Black Swan và cần disclaimer.
SON_SOC_05	Social Impact	Mở frontend trên màn hình nhỏ/mạng yếu, kiểm tra kết quả dự báo.	PayloadSizeKB, SocialChecklistScore	Người dùng thấy giá VND/kg, khoảng tin cậy, lời khuyên ngắn, disclaimer và cảnh báo vùng yếu.